

Architecture Multimodale pour l'Analyse et la Génération de recettes de cuisine

L'objectif de ce projet est de développer un *assistant intelligent* dédié à l'optimisation de la gestion culinaire quotidienne. En permettant la reconnaissance d'ingrédients par analyse d'images, l'outil doit pouvoir *générer des recettes personnalisées et cohérentes* (la banane à la moutarde c'est pas bon...), contribuant ainsi à la réduction du gaspillage alimentaire. En plus de cette fonctionnalité de suggestion, la plateforme intégrera un *module de calcul nutritionnel* transparent pour favoriser une gestion précise de l'alimentation. L'application produite doit également proposer une *interface conversationnelle* permettant une adaptation dynamique des recettes en fonction de contraintes spécifiques (allergies, régimes particuliers). Enfin, d'un point de vue technique, on **impose** :

- que le produit fonctionne sur *une architecture locale* garantissant une alimentation en données personnelles et une protection rigoureuse de la confidentialité de ces données.
- qu'une analyse d'impact environnemental soit effectuée, par exemple en utilisant [CodeCarbon](#)

Architecture Technique possible

Quelques outils possibles, non obligatoires. Vous pouvez en utiliser d'autres (outils et modèles).

- [Ollama](#). Ollama est un framework open-source conçu pour simplifier le déploiement, la gestion et l'exécution de modèles de langage de grande taille sur des machines personnelles, tout en offrant une interface fluide et une API accessible. de nombreux modèles sont accessibles via Ollama, par exemple : [Llama 3](#) pour le texte, [\[LLaVA\]](#) ([via Ollama](#)) pour l'analyse d'images.
- [Streamlit](#) pour une interface utilisateur
- [OpenWebUI](#) pour une interface web open source pour exécuter et gérer localement (ou à distance) des modèles de langage via Ollama ou des API compatibles OpenAI.

Livrables du Projet

Livrable 1 : Pipeline de Collecte et Socle de Connaissances

L'objectif est de constituer la base de données qui alimentera le système RAG (livrable 3).

- Développement de Scrapers : Création de scripts pour extraire des recettes depuis des sites spécialisés et des réseaux sociaux.
- Nettoyage et Modélisation : Structuration des données extraites (Titre, Ingrédients, Quantités, Étapes) au format JSON.
- Pipeline d'Embedding : Utilisation d'un modèle d'embedding local pour vectoriser les recettes et les stocker dans une base vectorielle.

Livrable : un dépôt de code contenant les scripts de scraping, le pipeline d'ingestion et un export de la base vectorielle contenant au minimum 500 recettes variées.

Liens utiles : Les liens suivants sont proposés à titre informatif. Ils ne sont surement pas exhaustifs.

- Scrapers : [BeautifulSoup](#), [Scrapy](#)

- Modèles d'embedding local : [all-MiniLM-L6-v2](#)
- Sites de recettes de cuisine : [Marmiton](#), [750g](#), [Cuisine AZ](#), [Journal des Femmes Cuisine](#), [Chef Simon](#)
- Bibliothèques open-source d'extraction de métadonnées ou de sous-titres de vidéos type TikTok/Instagram : (yt-dlp)[<https://github.com/yt-dlp/yt-dlp>], [Instaloader](#), [TikTokAPI](#)
- base de données vectorielle (stockage des embeddings): [ChromaDB](#), [FAISS](#)

Livable 2 : Moteur de Vision et Calculateur Nutritionnel

Ce module est le cœur analytique du projet. Il doit lier la perception visuelle à des données quantitatives précises.

- Analyse d'images (VLM) : Déploiement d'un modèle de vision-langage local (comme LLaVA via Ollama) capable de prendre une photo de plat ou d'ingrédients en entrée, d'identifier les composants, et de déduire un état (cru, cuit, type de cuisson).
- Estimation des Grammages : Implémentation d'un algorithme (heuristique basée sur des objets de référence dans l'image, ou prompt engineering avancé sur le VLM) pour estimer le poids relatif des ingrédients.
- Quantification Nutritionnelle : Création d'un script croisant les ingrédients et grammages identifiés (ou générés) avec une base de données de référence pour calculer dynamiquement les macros (glucides, lipides, protéines) par portion.

Livable : un module Python documenté avec des tests unitaires prouvant qu'une image ou une liste d'ingrédients en entrée ressort un dictionnaire structuré contenant les ingrédients, grammages estimés, et macros totaux.

Liens utiles :

- bases de données d'images [DeepFood](#), [FoodSeg](#), [Food500](#).
- base de données de composition nutritionnelle des aliments [Ciqal](#) ou [ici](#), [API OpenFoodFacts](#)

Livable 3 : Moteur de Génération et Agent Conversationnel (RAG & LLM)

Intégration de la logique conversationnelle et de la génération de recettes à partir des contraintes de l'utilisateur.

- Génération sous contrainte : ingénierie du prompt sur un modèle local pour générer des recettes cohérentes uniquement à partir d'une liste d'ingrédients fournis (mode "frigo vide").
- RAG : implémentation du chaînage permettant à l'utilisateur de poser des questions sur la recette générée ou sur la base scrapée (ex: "Par quoi puis-je remplacer le beurre ?", "Comment alléger cette recette en glucides ?"). La réponse doit nécessairement être sourcée (via ChromaDB par exemple).

Livable : une API locale ou des classes Python robustes exposant les endpoints de génération de recette et de Question/Answering, incluant la gestion de l'historique de conversation.

Liens utiles :

- Création d'API : [FastAPI](#)

- Orchestrateur et connecteur de LLM à des sources de données externes, des outils et des bases vectorielles : [LangChain](#), [LlamaIndex](#)

Livable 4 : Produit Final

L'orchestration de tous les modules précédents dans une interface utilisateur fluide, pensée pour un utilisateur final.

- Interface d'Upload & Analyse : Un module permettant de glisser-déposer une photo de son frigo ou d'un plat, affichant en temps réel le retour du VLM et les apports nutritionnels calculés.
- Générateur & Dashboard : Un panneau générant la recette étape par étape, avec un affichage visuel des macros (graphiques circulaires).
- Chatbot Contextuel : Une zone de chat interactive persistante permettant à l'utilisateur d'interagir avec la recette en cours d'affichage (le RAG et le LLM).
-

Livable : l'application Streamlit fonctionnelle (démarrable via `streamlit run app.py`), un fichier README.md complet (instructions de déploiement d'Ollama, téléchargement des poids des modèles, installation des dépendances).

Livable 5 : Présentation orale

Lors d'une séance de restitution aux trois promotions FISA, vous présenterez un pitch de 5 minutes en utilisant une présentation assistée par IA. Vous pouvez utiliser tout outil utile à ce propos. Vous ferez une analyse critique de la présentation obtenue, et de l'utilisation de l'IA pour ce type d'exercice.

Références

1. Salvador, A., Drozdal, M., Moiroux, X., Camire, I., Siro, M., & Ramos, G. (2019). Inverse Cooking: Recipe Generation from Food Images. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 10452-10461.

Résumé : Architecture Seq2Seq / Transformer permettant d'extraire la liste des ingrédients sous forme d'ensemble (set prediction) puis de prédire la séquence des étapes de préparation à partir d'une image de plat.

2. Chaitanya A., Shetty J., Chiplunka P., Food Image Classification and Data Extraction Using Convolutional Neural Network and Web Crawlers, *Procedia Computer Science*, 218, 143-152

Résumé : CNN et transfer learning avec scrapping pour la reconnaissance et la classification d'images d'aliments.

3. Marín, J., Biswas, A., Ofli, F., Hynes, N., Salvador, A., Aytar, Y., Weber, I., & Torralba, A. (2019). Recipe1M+: A Dataset for Learning Cross-Modal Embeddings for Cooking Recipes and Food Images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(1), 187-203.

Résumé : Présentation du jeu de données de référence (1,3 million d'images, 1 million de recettes) et de l'architecture d'espace d'embedding joint (joint embedding) liant vecteurs texte et vecteurs visuels.

4. Salvador, A., Hynes, N., Aytar, Y., Marin, J., Ofli, F., Weber, I., & Torralba, A. (2017). Learning Cross-Modal Embeddings for Cooking Recipes and Food Images. *Proceedings of the IEEE Conference on*

Résumé : Papier fondateur de l'approche Pic2Recipe utilisant des réseaux convolutifs (CNN) pour l'image et des LSTM pour le texte, optimisés par une perte de triplet (triplet loss).

5. Lee, H. H., Shu, K., Achananuparp, P., Prasetyo, P. K., Liu, Y., Lim, E. P., & Varshney, L. R. (2020). RecipeGPT: Generative Pre-training Based Cooking Recipe Generation and Evaluation System. *Proceedings of the Web Conference*, 181-184.

Résumé : Application des architectures autorégressives de type GPT-2 pour la génération conditionnelle de texte culinaire à partir d'ingrédients ou de titres.

6. Wang, H., Sahoo, D., Liu, C., Lim, E. P., & Hoi, S. C. (2019). Learning Cross-Modal Embeddings with Adversarial Networks for Cooking Recipes and Food Images. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 11564-11573.

Résumé : Utilisation de réseaux antagonistes génératifs (GANs) pour réduire le fossé sémantique (modality gap) entre l'espace vectoriel des images et celui des recettes textuelles.

7. Zhu, B., & Ngo, C. W. (2020). CookGAN: Causality Based Text-to-Image Synthesis. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 5518-5526.

Résumé : Modélisation des relations de causalité entre l'ajout séquentiel d'ingrédients, les méthodes de cuisson et la modification visuelle du plat final.

8. Mezgec, L., & Seljak, B. K. (2017). NutriNet: A Deep Learning Food Classification System for Dietary Assessment. *Nutrients*, 9(7), 653.

Résumé : Application des réseaux de neurones convolutifs à la reconnaissance visuelle de nourriture et à l'estimation automatique de valeurs nutritionnelles.

9. Diwakar, A. (2024). Deep Learning-Based Nutritional Analysis of Food Images Using EfficientNetB4 and Multilayer Perceptron. *Cureus*, 16(9).

Résumé : Combinaison de modèles de vision modernes (Backbone EfficientNet) et de régresseurs MLP pour prédire les macronutriments (glucides, lipides, protéines) directement à partir de clichés.

10. Papadopoulos, G. et al. (2023). An End-to-End Deep Learning System for Recommending Healthy Recipes. *International Journal of Advanced Computer Science and Applications*, 14(4).

Résumé : Intégration d'extraction visuelle d'ingrédients, de calcul automatique de scores nutritionnels et d'un système de recommandation personnalisé.

11. Zhang, D. et al. (2025). FoodLMM: A Versatile Food Assistant Using Large Multi-Modal Model. *arXiv preprint*.

Résumé : Utilisation de modèles multimodaux de grande taille (Large Multimodal Models) adaptés à la compréhension visuelle complexe de scènes culinaires et au dialogue interactif.